

Tarea 3 - Big Data

Curso: Big Data - Grupo 33 - B III 2026

Profesor: Gerardo Nereo Campos Araya.

Estudiantes

Andrés Esquivel Valerio 402500696

María Fernanda Granados Arias 402200492

Liz Madriz Rivera 117860659

Instrucciones de ejecución

Para ejecutar el notebook de la tarea, se debe levantar el entorno con Docker desde la carpeta raíz del proyecto **Big_Data_Tarea_03** con el siguiente comando:

```
docker compose up --build
```

Una vez levantados los contenedores, abrir el navegador y acceder a Jupyter en:

```
http://127.0.0.1:8888
```

Ingresar el token que aparece en la terminal al iniciar el contenedor. Abrir el archivo **notebooks/Tarea3.ipynb** y ejecutar todas las celdas desde el menú **Kernel** → **Restart & Run All**.

Para detener los contenedores al finalizar, ejecutar:

```
docker compose down
```

Estructura del proyecto

```
Big_Data_Tarea_03
├── .
├── Dockerfile
├── README.md
├── docker-compose.yaml
├── data/
├── wine.csv
├── notebooks/
├── Tarea3.ipynb
├── output/
├── docs/
└── ManualEjecucion.pdf
```

Descripción del proyecto

Este proyecto implementa un pipeline de Machine Learning con Apache Spark para la clasificación binaria de calidad de vinos tintos. A partir del dataset Wine Quality Binary Classification obtenido de Kaggle, se preparan los datos, se entrenan dos modelos de clasificación y se evalúan sus resultados utilizando K-Fold Cross Validation. Los datos procesados y las predicciones se almacenan en una instancia de PostgreSQL ejecutada en un contenedor Docker. Entre los

resultados obtenidos están:

- La predicción de calidad de vino (buena/mala) a partir de variables fisicoquímicas.
- Estadísticas descriptivas y análisis de correlación entre variables.
- Métricas de evaluación: AUC-ROC, Accuracy y F1-Score para cada modelo.
- Predicciones persistidas en las tablas **modelo1** y **modelo2** en PostgreSQL.
- Análisis comparativo del desempeño de ambos modelos.